

Laporan Analisis

Neural IR dengan Transformer & BERT

Kelompok 4 :

- 14250028 - Hanief Fathul Bahri Ahmad
- 14250029 - Irfan Wibowo
- 14250027 - Muhammad Arief Nadhofa

Part 1 - FiRA Judgement Aggregation


Metodologi :

Judgement Aggregation adalah proses menggabungkan beberapa penilaian dari beberapa annotator untuk setiap satu query dokumen menjadi satu nilai konsensus. Pada part 1 menggunakan dataset dari FiRA, setiap pasangan (query_id, doc_id) dinilai oleh 3 annotator yang berbeda.

query_id	doc_id	annotator	judgement	confidence
1	d1_3	User_1	1	0.87
1	d1_3	User_2	2	0.65
1	d1_3	User_0	1	0.58

Tanpa agregasi, data tetap berupa tiga nilai terpisah (1, 2, 1) tanpa keputusan final untuk evaluasi. Dengan agregasi, ketiganya digabung menjadi satu nilai konsensus, yaitu 1 (berdasarkan mayoritas 2:1 atau metode lanjutan). Notebook menguji tiga pendekatan: simple majority voting, confidence-based weighting, dan reliability-weighted voting.

A. Simple Majority Voting



Simple Majority Voting digunakan sebagai baseline agregasi. Pada metode ini, skor akhir ditentukan dari nilai judgement yang paling sering muncul pada satu pasangan query-doc. Metode ini sederhana, mudah dijelaskan, dan cukup kuat ketika mayoritas annotator memberikan penilaian yang sama.

B. Advanced: Confidence-Based Weighting

metode ini memakai nilai confidence sebagai bobot judgement. Semakin tinggi confidence annotator, semakin besar pengaruhnya terhadap skor akhir. Metode ini berguna saat ada perbedaan pendapat antar annotator, karena hasilnya bisa beda dari majority voting yang cuma ngitung suara terbanyak

C. Advanced: Reliability-Weighted Voting

Reliability-Weighted Voting adalah metode agregasi yang memberi bobot berdasarkan reliabilitas (keandalan) annotator. Reliabilitas dihitung dari seberapa sering annotator setuju dengan voting terbanyak. Annotator yang lebih sering konsisten dengan konsensus mendapat bobot lebih tinggi, sedangkan yang sering berbeda mendapat bobot lebih rendah.

Total Relability Per Annotator

Annotator	Reliability
User 0	0.7692
User 1	0.8372
User 2	0.7805
User 3	0.7660
User 4	0.8276
User 5	0.7632

D. Hasil Agregasi dan Perbandingan

Perbandingan Simple Voting dan Advanced

Perbandingan	Jumlah pasangan	Score berbeda	Distribusi score diff
Majority vs Confidence-Based Weighting	79	6	-1: 4, 0: 73, +1: 2
Majority vs Reliability-Weighted Voting	79	6	-1: 4, 0: 73, +1: 2

Hasil pada tabel menunjukkan bahwa metode advanced hanya mengubah 6 dari 79 pasangan dibandingkan Simple Majority Voting. Ini berarti hasil agregasi mayoritas sudah cukup kuat, berarti mayoritas judgement pada data FiRA sudah cukup konsisten, sehingga faktor confidence dan reliability hanya mengubah sedikit hasil yang kemungkinan berasal dari perbedaan kecil atau outlier antar-annotator.

Perbandingan Baseline Qrels FiRA 2022 dengan Advanced

Metode Advanced	Matched pairs	Exact match	Exact match rate	Mean absolute difference	Distribusi score diff
Confidence-Based Weighting	79	73	0.9241	0.0759	-1: 4, 0: 73, +1: 2
Reliability-Weighted Voting	79	73	0.9241	0.0759	-1: 4, 0: 73, +1: 2

Kedua metode advanced memiliki tingkat kecocokan tinggi terhadap baseline, yaitu 73 dari 79 pasangan atau 92,41%. Nilai mean absolute difference yang kecil menunjukkan bahwa perbedaan judgement tidak besar, sehingga metode advanced dapat dianggap konsisten dan cukup representatif terhadap baseline FiRA 2022.

E. Analisis Disagreement Tinggi

Disagreement tinggi dianalisis dengan membandingkan judgement mentah dari setiap annotator dengan hasil agregasi menggunakan metode advanced berbasis confidence. Analisis ini bertujuan untuk melihat

bagaimana metode advanced menentukan skor akhir ketika terdapat perbedaan penilaian yang cukup besar antar-annotator.

Disagreement Tinggi pada FiRA dan discore dengan Advanced by Confidence

Query ID	Doc ID	Judgement mentah	Confidence	Aggregated score	Std score
9	d9_3	0, 0, 2	0.67, 0.96, 0.64	1	0.94
6	d6_7	0, 2, 2	0.97, 0.85, 0.55	1	0.94
4	d4_7	0, 2, 2	0.93, 0.82, 0.87	1	0.94
9	d9_2	3, 3, 1	0.67, 0.56, 0.59	2	0.94
6	d6_2	1, 3, 2	0.95, 0.67, 0.95	2	0.82

Jika nilai setiap annotator beda jauh, metode advanced ini cenderung ambil jalan tengah. Contohnya di d9_3, d6_7, dan d4_7 yang polanya (0,0,2) atau (0,2,2), hasil akhirnya malah jadi 1. Karena, annotator yang kasih nilai 0 mempunyai confidence tinggi, jadi pengaruhnya lebih besar dan skor akhir tidak mengikuti mayoritas yang nilai 2. Di sisi lain, d9_2 dengan pola (3,3,1) skornya turun ke 2 karena ada satu nilai rendah. Sedangkan d6_2 yang polanya (1,3,2) relatif seimbang secara matematis karena rata-rata dari ketiga nilai tersebut adalah 2.

Part 2 - BERT Cross-Encoder Re-Ranking

A. Analisa Fungsi train pada BERTCrossEncoder

Fungsi ini mengubah model cross-encoder yang awalnya sudah dilatih pada MS MARCO menjadi lebih sesuai dengan pasangan query-passage dari FiRA. Fungsi ini menerima train_df, membuat dataset, membangun DataLoader, lalu melakukan optimasi parameter model selama beberapa epoch.

Analisa Komponen Utama Fungsi train

Tahap pada def train	Analisa
CrossEncoderDataset	Mengubah query, passage, dan label menjadi input model. Query dan passage dipasangkan dalam satu encoding sehingga BERT dapat membaca hubungan keduanya secara langsung.
DataLoader	Membagi data menjadi batch kecil dan melakukan shuffle agar urutan data tidak memengaruhi proses pembelajaran.
Adam optimizer	Memperbarui bobot model dengan learning rate 2e-5, nilai yang umum dipakai untuk fine-tuning transformer agar perubahan bobot tidak terlalu agresif.
BCEWithLogitsLoss	klasifikasi biner relevan dan tidak relevan. Loss dihitung dari logits model sebelum sigmoid.

Loop epoch	Setiap epoch melakukan forward pass, menghitung loss, backpropagation, optimizer.step, lalu reset gradien dengan optimizer.zero_grad.
------------	---

Pada fungsi train, label diubah menjadi float karena BCEWithLogitsLoss membutuhkan target bernilai numerik float. Secara konsep, fungsi train melatih model untuk memberi skor lebih tinggi pada passage yang relevan terhadap query dan skor lebih rendah pada passage yang tidak relevan. Karena cross-encoder memproses query dan passage secara bersamaan, model dapat menangkap interaksi kata antar keduanya, bukan hanya mencocokkan embedding secara terpisah.

C. Hasil Fine-tuning pada FiRA

Model yang digunakan adalah cross-encoder/ms-marco-MiniLM-L-6-v2 dan dijalankan pada GPU CUDA. Training dilakukan selama 5 epoch pada data FiRA yang telah diberi label biner. Nilai loss per epoch menunjukkan tren penurunan yang cukup jelas.

Perkembangan Loss Fine-tuning FiRA

Epoch	Average Loss	Interpretasi
1	0.6521	Model masih beradaptasi dengan pola data FiRA.
2	0.4738	Loss turun, model mulai membedakan pasangan relevan dan tidak relevan.
3	0.2976	Performa training semakin baik.
4	0.3251	Terjadi sedikit kenaikan loss, kemungkinan karena ukuran data kecil dan variasi batch.
5	0.1555	Loss paling rendah, menunjukkan model semakin fit pada data training FiRA.

D. FiRA Re-rank dengan BERT Fine-Tuned

Setelah fine-tuning, model digunakan untuk melakukan re-ranking. Untuk setiap query, seluruh passage kandidat diberi relevance score. Berikut preview 1 pasangan per query berdasarkan scorenya.

Contoh Dokumen Teratas Hasil Re-ranking FiRA

Query	Peringkat Teratas	Score	Label
1	d1_1	0.9999	1
1	d1_2	0.9994	1
4	d4_1	1.0000	1
7	d7_1	0.9999	1
10	d10_1	0.9999	1

Query 8

1. d8_1 (score=0.9997, relevant=1)
2. d8_7 (score=0.9992, relevant=0)
3. d8_2 (score=0.9947, relevant=1)
4. d8_5 (score=0.3787, relevant=0)
5. d8_4 (score=0.0919, relevant=0)
6. d8_3 (score=0.0062, relevant=0)
7. d8_6 (score=0.0001, relevant=0)
8. d8_8 (score=0.0000, relevant=0)

D8_7

queries : what causes earthquakes

passage: Earthquakes can trigger secondary disasters such as landslides, volcanic activity, and tsunamis. The shaking of the ground can also cause liquefaction of soil, damaging buildings.

Hasil tersebut menunjukkan bahwa model cukup baik dalam menempatkan dokumen relevan di posisi atas. Namun, ada juga kasus ketika dokumen berlabel 0 memperoleh skor tinggi, misalnya d8_7 memperoleh skor 0.9992 tetapi memiliki nilai relevant 0. Hal ini karena isi passage secara semantik masih mirip dengan query, meskipun judgement agregasi menilainya tidak relevan. Ini adalah contoh bahwa cross-encoder sensitif terhadap kemiripan makna, tetapi tetap membutuhkan evaluasi berbasis qrels untuk memastikan kualitas ranking.

E. Evaluasi FiRA: First-stage vs BERT Re-ranker

Perbandingan Evaluasi pada Dataset FiRA

Dataset	Model	MRR@10	NDCG@10	Precision@10	Num Queries
FiRA	First-stage / Original Order	1.0000	0.927538	0.4500	10
FiRA	BERT Cross-Encoder Re-Ranker	1.0000	0.937349	0.4500	10

MRR@10 bernilai 1.0000 pada kedua metode, artinya dokumen relevan pertama sudah muncul pada rank pertama untuk setiap query yang dievaluasi. Precision@10 juga tetap 0.4500, sehingga jumlah dokumen relevan dalam 10 besar tidak berubah. Perbedaan utama terlihat pada NDCG@10, yang naik dari 0.927538 menjadi 0.937349. Kenaikan ini menunjukkan bahwa BERT Cross-Encoder tidak hanya menemukan dokumen relevan, tetapi sedikit memperbaiki urutan dokumen berdasarkan tingkat relevansinya.

F. Evaluasi MS MARCO Menggunakan Model Fine-tuned FiRA

Model yang sudah di-fine-tune pada FiRA diuji pada MS MARCO. Evaluasi menggunakan 1000 query sampel, 96.946 kandidat passage, dan 1.045 qrels. Hasilnya jauh lebih rendah dibandingkan FiRA.

Evaluasi Akhir FiRA dan MS MARCO

Dataset	Model	MRR@10	NDCG@10	Precision@10	Num Queries
FiRA	First-stage / Original Order	1.000000	0.927538	0.4500	10
FiRA	BERT Cross-Encoder Re-Ranker	1.000000	0.937349	0.4500	10
MS MARCO	BERT Fine-tuned (FiRA)	0.081991	0.089668	0.0114	1000

Nilai MRR@10 sebesar 0.081991, NDCG@10 sebesar 0.089668, dan Precision@10 sebesar 0.0114 menunjukkan bahwa model yang diadaptasi pada FiRA tidak langsung kuat saat diterapkan ke MS MARCO. Penyebab utamanya adalah perbedaan skala dan domain. FiRA hanya memiliki 79 pasangan training, sedangkan MS MARCO memiliki kandidat jauh lebih banyak dan variasi query-passage yang lebih luas. Kemungkinan data kecil dapat meningkatkan kecocokan pada dataset target kecil, tetapi belum tentu meningkatkan di dataset besar.

Part 3 - Extractive QA

Model BERT Cross-Encoder dari Part 2 untuk pemilihan passage paling relevan, kemudian model Extractive QA mengambil potongan jawaban langsung dari passage teratas.

A. Re-Ranking Passage dengan BERT Cross-Encoder

Setiap candidate passage diberi skor oleh Cross-Encoder. Setiap query passage diurutkan berdasarkan reranker_score, kemudian top passage digunakan sebagai konteks untuk Extractive QA. Hasil ranking menunjukkan MRR@10 sebesar 1.000000, artinya dokumen relevan pertama selalu muncul pada peringkat pertama untuk 10 query yang diuji.

Metrik Ranking

Dataset	Model	MRR@10	NDCG@10	Precision@10	Num Queries
FiRA	BERT Cross-Encoder	1.000000	0.939122	0.4500	10

B. Hasil Extractive QA

Extractive QA dijalankan pada top passage hasil re-ranking. Untuk setiap query, model memilih jawaban dengan qa_score tertinggi. Pada hasil FiRA, semua query berhasil memperoleh jawaban dari salah satu passage teratas.

Contoh Jawaban Extractive QA

Query	Jawaban Final	QA Score	Sumber	Rank
how to make a good cappuccino	double espresso, hot milk, and steamed milk foam on top	0.334059	d1_3	3
why is the sky blue	Rayleigh scattering	0.509754	d2_1	1
what is photosynthesis in plants	Chloroplasts	0.755266	d3_7	4
symptoms of heart attack	chest tightness, pain radiating down the left arm, sweating, dizziness, and feeling short of breath	0.416668	d4_2	2
average lifespan of a domestic cat	12 to 15 years	0.888389	d6_1	1

Data diatas menjelaskan bahwa jawaban tidak selalu berasal dari rank 1. Pada query cappuccino, jawaban terbaik berasal dari d1_3 pada rank 3 karena passage tersebut memuat definisi komponen cappuccino secara eksplisit. Pada query photosynthesis, jawaban berasal dari d3_7 pada rank 4 karena span “Chloroplasts” dianggap paling langsung menjawab pertanyaan.

C. Evaluasi Sumber Jawaban QA

Metrik Sumber Jawaban QA

QA_Source_Hit_Rate	QA_Source_MRR	Avg_QA_Score	Avg_Source_Rank	Num Queries
1.000000	0.758333	0.617730	1.700000	10

QA_Source_Hit_Rate sebesar 1.000000 berarti seluruh jawaban berasal dari dokumen yang relevan menurut qrels. QA_Source_MRR sebesar 0.758333 menunjukkan bahwa sebagian besar sumber jawaban berada pada peringkat atas. Avg_Source_Rank sebesar 1.7 juga memperkuat bahwa rata-rata diambil dari dokumen rank 1 sampai 2, meskipun ada beberapa kasus di rank 3 dan rank 4.

Detail Evaluasi Sumber Jawaban

Query ID	Source Doc	Source Rank	Relevance	Source MRR	QA Score
1	d1 3	3	1	0.333333	0.334059
2	d2 1	1	3	1.000000	0.509754
3	d3 7	4	1	0.250000	0.755266
4	d4 2	2	3	0.500000	0.416668
5	d5 1	1	2	1.000000	0.414659
6	d6 1	1	2	1.000000	0.888389
7	d7 1	1	2	1.000000	0.989471
8	d8 2	2	2	0.500000	0.551264
9	d9 1	1	2	1.000000	0.913628
10	d10 1	1	3	1.000000	0.404139

Ringkasan Evaluasi Part 3

Dataset	Model	MRR@10	NDCG@10	Precision@10	QA Hit Rate	QA Source MRR	Avg QA Score	Num Queries
FiRA	BERT Cross-Encoder + Extractive QA	1.000000	0.939122	0.4500	1.000000	0.758333	0.617730	10

Kombinasi Cross-Encoder dan Extractive QA bekerja cukup baik pada FiRA. Cross-Encoder berhasil mempertahankan dokumen relevan pada urutan atas, sedangkan Extractive QA mampu mengambil jawaban eksplisit dari dokumen yang relevan untuk semua query.

Kesimpulan & Tantangan

A. Kesimpulan

Hasil dari ketiga part menunjukkan bahwa pendekatan Neural IR yang digunakan dapat membentuk alur pencarian informasi yang cukup jelas, mulai dari penentuan label relevansi, pengurutan dokumen, sampai pengambilan jawaban. Pada Part 1, hasil agregasi judgement menunjukkan bahwa penilaian antar-annotator pada data FiRA relatif konsisten, karena metode advanced hanya sedikit mengubah hasil majority voting. Pada Part 2, fine-tuning BERT Cross-Encoder membantu memperbaiki urutan dokumen pada FiRA, terutama terlihat dari peningkatan NDCG@10, tetapi performanya menurun saat diuji pada MS MARCO karena perbedaan jumlah data dan variasi passage yang jauh lebih besar. Pada Part 3, hasil Extractive QA memperlihatkan bahwa jawaban yang diambil masih berasal dari dokumen relevan, meskipun tidak selalu dari peringkat pertama.

B. Tantangan

- Bingung mencari data MS Marco yang kecil. Akhirnya bisa via `ir_dataset` dan hanya ambil yang top 1000 saja

- Terkadang bingung perubahan float atau melakukan pembulatan pada score malah membuat hasil tidak maksimal.
- Belum bisa mendapatkan strategi yang performa dan statistiknya melebihi strategi pertama, saat ini masih sama saja hasilnya.

Pembagian Tugas

Nama	Tugas
Irfan Wibowo	Mengerjakan starter code Part 1 dan Part 2, mulai dari agregasi judgement sampai implementasi BERT Cross-Encoder. Lalu melakukan analisis awal untuk hasil agregasi, re-ranking FiRA, dan performa awal BERT setelah fine-tuning.
Hanief Fathul Bahri Ahmad	Mengoreksi notebook Part 1 & 2, merapikan struktur folder proyek serta menulis kembali laporan secara lebih jelas dan terstruktur, menerapkan evaluasi MS MARCO, mengoptimalkan fungsi dengan mengganti optimizer dan menerapkan loss function BCEWithLogitsLoss pada evaluasi perbandingan FiRA First-stage vs BERT Re-ranker dan melakukan adjustment fine tuning pada part 2, memindahkan main class ke dalam file extractive_qa.py terpisah, serta membuat analisis sederhana untuk Part 3.
Muhammad Arief Nadhofa	Mengerjakan starter code Part 3 untuk re-ranking passage dengan BERT Cross-Encoder, Extractive QA pada top passage, dan evaluasi sumber jawaban.