

Laporan Analisis

Neural IR dengan Transformer & BERT

Kelompok 4 :

- 14250027 - Muhammad Arief Nadhoha
- 14250028 - Hanief Fathul Bahri Ahmad
- 14250029 - Irfan Wibowo

1. Pendahuluan

Part 1 - FiRA Judgement Aggregation


Metodologi :

Judgement Aggregation adalah proses menggabungkan beberapa penilaian dari beberapa annotator untuk setiap satu query dokumen menjadi satu nilai konsensus. Pada part 1 menggunakan dataset dari FiRA, setiap pasangan (query_id, doc_id) dinilai oleh 3 annotator yang berbeda.

query_id	doc_id	annotator	judgement	confidence
1	d1_3	User_1	1	0.87
1	d1_3	User_2	2	0.65
1	d1_3	User_0	1	0.58

Tanpa agregasi, data tetap berupa tiga nilai terpisah (1, 2, 1) tanpa keputusan final untuk evaluasi. Dengan agregasi, ketiganya digabung menjadi satu nilai konsensus, yaitu 1 (berdasarkan mayoritas 2:1 atau metode lanjutan). Notebook menguji tiga pendekatan: simple majority voting, confidence-based weighting, dan reliability-weighted voting.

A. Simple Majority Voting



Simple Majority Voting digunakan sebagai baseline agregasi. Pada metode ini, skor akhir ditentukan dari nilai judgement yang paling sering muncul pada satu pasangan query-doc. Metode ini sederhana, mudah dijelaskan, dan cukup kuat ketika mayoritas annotator memberikan penilaian yang sama.

B. Advanced: Confidence-Based Weighting

metode ini memakai nilai confidence sebagai bobot judgement. Semakin tinggi confidence annotator, semakin besar pengaruhnya terhadap skor akhir. Metode ini berguna saat ada perbedaan pendapat antar annotator, karena hasilnya bisa beda dari majority voting yang cuma ngitung suara terbanyak

C. Advanced: Reliability-Weighted Voting

Reliability-Weighted Voting adalah metode agregasi yang memberi bobot berdasarkan reliabilitas (keandalan) annotator. Reliabilitas dihitung dari seberapa sering annotator setuju dengan voting terbanyak. Annotator yang lebih sering konsisten dengan konsensus mendapat bobot lebih tinggi, sedangkan yang sering berbeda mendapat bobot lebih rendah.

Total Reliability Per Annotator

Annotator	Reliability
User 0	0.7692
User 1	0.8372
User 2	0.7805
User 3	0.7660
User 4	0.8276
User 5	0.7632

D. Hasil Agregasi dan Perbandingan

Perbandingan Simple Voting dan Advanced

Perbandingan	Jumlah pasangan	Score berbeda	Distribusi score diff
Majority vs Confidence-Based Weighting	79	6	-1: 4, 0: 73, +1: 2
Majority vs Reliability-Weighted Voting	79	6	-1: 4, 0: 73, +1: 2

Hasil pada tabel menunjukkan bahwa metode advanced hanya mengubah 6 dari 79 pasangan dibandingkan Simple Majority Voting. Ini berarti hasil agregasi mayoritas sudah cukup kuat, berarti mayoritas judgement pada data FiRA sudah cukup konsisten, sehingga faktor confidence dan reliability hanya mengubah sedikit hasil yang kemungkinan berasal dari perbedaan kecil atau outlier antar-annotator.

Perbandingan Baseline Qrels FiRA 2022 dengan Advanced

Metode Advanced	Matched pairs	Exact match	Exact match rate	Mean absolute difference	Distribusi score diff
Confidence-Based Weighting	79	73	0.9241	0.0759	-1: 4, 0: 73, +1: 2
Reliability-Weighted Voting	79	73	0.9241	0.0759	-1: 4, 0: 73, +1: 2

Kedua metode advanced memiliki tingkat kecocokan tinggi terhadap baseline, yaitu 73 dari 79 pasangan atau 92,41%. Nilai mean absolute difference yang kecil menunjukkan bahwa perbedaan judgement tidak besar, sehingga metode advanced dapat dianggap konsisten dan cukup representatif terhadap baseline FiRA 2022.

E. Analisis Disagreement Tinggi

Disagreement tinggi dianalisis dengan membandingkan judgement mentah dari setiap annotator dengan hasil agregasi menggunakan metode advanced berbasis confidence. Analisis ini bertujuan untuk melihat bagaimana metode advanced menentukan skor akhir ketika terdapat perbedaan penilaian yang cukup besar antar-annotator.

Disagreement Tinggi pada FiRA dan discore dengan Advanced by Confidence

Query ID	Doc ID	Judgement mentah	Confidence	Aggregated score	Std score
9	d9_3	0, 0, 2	0.67, 0.96, 0.64	1	0.94
6	d6_7	0, 2, 2	0.97, 0.85, 0.55	1	0.94
4	d4_7	0, 2, 2	0.93, 0.82, 0.87	1	0.94
9	d9_2	3, 3, 1	0.67, 0.56, 0.59	2	0.94
6	d6_2	1, 3, 2	0.95, 0.67, 0.95	2	0.82

Pada kasus d9_3, dua annotator memberikan judgement 0, tetapi satu annotator memberikan judgement 2. Dengan adanya pembobotan, skor akhir menjadi 1. Ini menunjukkan bahwa metode advanced dapat menghasilkan nilai tengah ketika terdapat perbedaan tajam antar penilai. Pola serupa terlihat pada d6_7 dan d4_7, yang memiliki judgement 0, 2, dan 2 namun hasil agregasinya menjadi 1. Hal ini dapat terjadi karena confidence pada judgement 0 cukup tinggi, sehingga pengaruhnya menahan skor final agar tidak langsung mengikuti mayoritas 2.

Kasus d9_2 memiliki judgement 3, 3, dan 1 dengan aggregated score 2. Artinya, meskipun mayoritas memberi nilai sangat relevan, adanya satu nilai rendah membuat skor akhir turun ke tingkat sedang. Kasus d6_2 lebih seimbang karena judgement-nya 1, 3, dan 2. Skor akhir 2 dapat dianggap wajar karena berada di tengah variasi penilaian.

Part 2 - BERT Cross-Encoder Re-Ranking

kode